



# NI MADE SRI KUMALA

# **DEWI OKA**

Freshgraduate Mathematics Udayana University

Supported by: Rakamin Academy Career Acceleration School www.rakamin.com Connect with me!





Sri Kumala Dewi

### **Overview**





Tulisan ini memuat analisa perilaku pelanggan yang mengajukan pinjaman kepada bank yang menyediakan layanan pinjaman uang untuk pembelian properti. Analisa dilakukan untuk mengetahui minat pelanggan terhadap tipe properti dan pengaruh status perkawinan terhadap jangka waktu peminjaman.





# Dataset yang Digunakan





#### **Loan Customer**

Deskripsi

Dataset ini menggambarkan perilaku dan profil pelanggan di sebuah bank yang menyediakan program pinjaman untuk pembelian property

- Data


Setiap baris mewakili pelanggan, setiap kolom berisi atribut pelanggan





### **Informasi Dataframe**





#### **Hasil Analisis**

- 1. Terdapat 621 baris (data) dengan 17 kolom (features)
- 2. Pada beberapa features terlihat memiliki null/missing values yang ditandai dengan null count < baris
- 3. Ada kesalahan type data pada kolom phone\_number dan birth\_date sehingga perlu dilakukan konversi tipe data.

### **Informasi Dataframe**



#### **Handling dtypes error**

```
df loan['birth date'] = pd.to datetime(df loan['birth date'])
df loan['phone number'] = df loan['phone number'].astype(str)
df loan.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 621 entries, 0 to 620
Data columns (total 17 columns):
                        Non-Null Count Dtype
     Column
                        621 non-null
                                        object
    loan id
    birth date
                        572 non-null
                                        datetime64[ns]
                        621 non-null
     phone number
                                        object
                        608 non-null
     gender
                                         object
     married
                        618 non-null
                                        object
    <u>de</u>pendents
                        605 non-null
                                        object
    education
                        620 non-null
                                        object
    self employed
                        588 non-null
                                        object
     applicant income
                        612 non-null
                                         float64
                                         float64
     coapplicant income 621 non-null
    loan amount
                        621 non-null
                                         int64
 11 loan term month
                        621 non-null
                                         int64
 12 loan term year
                        621 non-null
                                         int64
 13 credit history
                        570 non-null
                                         float64
    has credit card
                        88 non-null
                                        object
    property type
                        620 non-null
                                        object
 16 loan status
                        621 non-null
                                         object
dtypes: datetime64[ns](1), float64(3), int64(3), object(10)
memory usage: 82.6+ KB
```

#### **Hasil Analisis**

Semua tipe data sudah sesuai

## **Missing Values**



```
# Informasi banyaknya missing values di tiap feature
df_loan.isnull().sum()
loan id
birth date
phone number
gender
married
dependents
                       16
education
self employed
applicant_income
coapplicant income
loan amount
loan term month
loan term year
                        0
credit history
has_credit_card
                      533
property_type
loan status
                        0
dtype: int64
```

#### **Hasil Analisis**

Feature has\_credit\_card memiliki missing values terbanyak, sehingga feature ini akan dibuang (drop) bersamaan dengan baris data yang memiliki missing values lainnya.

### Missing Values



#### **Handling Missing Values**

```
# Membuang kolom yang memiliki missing values terbanyak
df_loan.drop('has_credit_card', axis=1, inplace=True)

# Menghapus baris NaN
df_loan = df_loan.dropna()

# Melihat jumlah data
print(df_loan.info())
print('\nUkuran data : {}'.format(df_loan.shape))
```


#### **Hasil Analisis**

- Jumlah features menjadi 16 karena ada features yang dibuang
- 2. Jumlah data yang lengkap sebanyak 472 data

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 472 entries, 0 to 619
Data columns (total 16 columns):
                        Non-Null Count Dtype
     Column
     loan id
                                        object
                        472 non-null
    birth date
                        472 non-null
                                        datetime64[ns]
                        472 non-null
                                        object
     phone number
     gender
                        472 non-null
                                        object
     married
                        472 non-null
                                        object
                        472 non-null
                                        object
     dependents
    education
                        472 non-null
                                        object
    self employed
                        472 non-null
                                        object
    applicant income
                        472 non-null
                                        float64
     coapplicant income 472 non-null
                                        float64
     loan amount
                        472 non-null
                                        int64
     loan term month
                        472 non-null
                                         int64
     loan term year
                        472 non-null
                                         int64
     credit history
                        472 non-null
                                        float64
    property type
                        472 non-null
                                        object
                        472 non-null
 15 loan status
                                        object
dtypes: datetime64[ns](1), float64(3), int64(3), object(9)
memory usage: 62.7+ KB
None
Ukuran data: (472, 16)
```

## **Duplicated Values**





#### **Hasil Analisis**

Terdapat 5 data duplikat pada dataset sehingga harus dihapus agar tidak merusak kesimpulan analisis akhir.

## **Duplicated Values**



#### **Handling duplicated Data**

```
# Menghapus data duplikat

df_loan.drop_duplicates(inplace=True)

# Mengecek kembali apakah ada data duplikat

print(f'Banyaknya data duplikat : {df_loan.duplicated().sum()}')

print(f'Jumlah data setelah data duplikat dihapus : {len(df_loan)}')

Banyaknya data duplikat : 0

Jumlah data setelah data duplikat dihapus : 467
```


#### **Hasil Analisis**

Data duplikat sudah dihapus dan menyisakan 467 data.

# **Handling Outlier**



#### **Hasil Analisis**



Outlier terlihat jelas pada data applicant\_income, coapplicant\_income, dan loan\_amount. Data outlier dapat merusak sebaran data sehingga akan dilakukan metode zscores untuk menghapus data tersebut.

## **Handling Outlier**



#### **Handling Outlier**

```
[296] # # Handling Outlier

from scipy.stats import zscore

print(f'Jumlah baris sebelum handling outlier : {len(df_loan)}')

z = np.abs(zscore(df_loan[num_df]))
    threshold = 3
    df_loan_clean = df_loan[(z < threshold).all(axis=1)]


print(f'Jumlah baris sesudah handling outlier : {len(df_loan_clean)}')

Jumlah baris sebelum handling outlier : 467
Jumlah baris sesudah handling outlier : 439</pre>
```

# **Handling Outlier**



#### **Hasil Analisis**



Outlier tidak hilang sepenuhnya namun sudah lebih baik dari sebelumnya

### **Feature Encoding**



#### **Mapping Encoding**

```
[56] # Mapping cat df
    mapping gender = {
         'Female' : 0,
         'Male' : 1
    mapping married = {
         'No' : 0,
    mapping education = {
         'Not Graduate' : 0,
         'Graduate' : 1
    mapping dependents = {
         '0': 0.
        '1':1,
        '2': 2,
```

```
mapping self employed = {
    'No' : 0,
mapping_property_type = {
    'apartment' : 0,
    'house' : 1,
    'studio' : 2
df encode['gender'] = df encode['gender'].map(mapping gender)
df encode['married'] = df encode['married'].map(mapping married)
df encode['education'] = df encode['education'].map(mapping education)
df_encode['self_employed'] = df_encode['self_employed'].map(mapping_self_employed)
df encode['property type'] = df encode['property type'].map(mapping property type)
df encode['dependents'] = df encode['dependents'].map(mapping dependents)
```

## **Feature Encoding**



#### **Hasil Analisis**

[57] df_encode.head()												
		loan_id	birth_date	phone_number	gender	married	dependents	education	self_employed	applicant_income	coapplicant_income	loan_a
	0	LP001002	1977-05-15	628114203187.0	1	0	0	1	0	5849.0	0.0	1
	1	LP001003	1979-08-24	628776449212.0	1	1	1	1	0	4583.0	1508.0	1
	2	LP001005	1991-03-28	628119240537.0	1	1	0	1	1	3000.0	0.0	
	3	LP001006	1980-06-02	62856343702.0	1	1	0	0	0	2583.0	2358.0	1
	4	LP001008	1989-05-19	628113008687.0	1	0	0	1	0	6000.0	0.0	1
	4 (	_										

Nilai pada feature categorical sudah berubah sesuai dengan proses mapping encode sebelumnya.






# Analisis Minat Pelanggan Berdasarkan Pada Tipe Properti






### Analisis Pengaruh Status Perkawinan Terhadap Jangka Waktu Meminjam











## Kesimpulan





Berdasarkan analisa yang telah dilakukan, nasabah yang mengajukan peminjaman pada bank memiliki karakteristik sebagai berikut :

- Lebih meminati properti apartemen dibanding studio dan rumah
- 2. Cenderung melakukan peminjaman dengan jangka waktu 30 tahun



